

1 Personal opinion and difficulties

Realizar estas prácticas ha sido bastante complicado, no por estas en sí, sino por la programación del máster. Ha sido un asunto transversal, que ha atravesado el desarrollo todas las asignaturas, debido a la organización del tiempo. Al intentar seguir el programa y realizar todas las asignaturas a alvez, se evidencia una falta de horas en el día para avanzar todas las tareas. De esta manera, al ser unas prácticas online en la que debería trabajar a mi ritmo, la mayor parte del trabajo se ha ido posponiendo hasta que fuera inevitable.

Además de este asunto, también he tenido mi aprendizaje y dificultades particulares de esta práctica. El principal asunto ha sido el síndrome de la página en blanco, podríamos llamarlo. En contré una gran dificultad a la hora de encontrar un paper sobre el que empezar a trabajar, al pensar que no iba a ser la elección idónea. Además de tener una serie de requisitos, que no se iban a cumplir perfectamente, había que ser realista, iba pasando de paper a paper buscando un tema en el que centrarme, lo cual era muy complicado ya que nada me convencía al 100%.

A este problema se le sumó el hecho de que la metabolómica está bastante más atrasada que el resto de ómicas. Quizá sea por su naturaleza de estudio, ya que mientras que la proteómica y la genómica estudian secuencias de proteínas o ácidos nucleicos con estructuras bastante fijas y definidas, la metabolómica estudia la presencia y cantidad de diferentes metabolitos y sus interacciones, lo que es bastante más complicado de estudiar conceptual y realísticamente, al haber una gran parte de confusión y ruido al pasar de secuencias de proteínas a metabolitos. Esto implica que hay pocas bases de datos de las que extraer información, hay pocos estudios que construyan unos sobre otros, superponiendo información y creando algo similar al genoma humano, por ejemplo. Por el momento solo tenemos bases de datos que contienen los resultados experimentales de cada grupo de investigación si eso.

Otro problema que surgió fue la mala replicabilidad de los papers. Una tendencia general de estos papers es de disponer de una mala replicabilidad, habiendo una falta, no solo del código empleado en sí, sino de versiones, parámetros y técnicas que son esenciales para la obtención de los datos.

A la hora de descargar los datos necesarios de las pocas bases de datos existentes, se hace patente la falta de infraestructura desarrollada para este campo de investigación. La información más sencilla de acceder fue aquella obtenida mediante secuenciación, subidas como SRA al NIH. Los resultados de secuenciación de pequeño tamaño, como es el caso de las muestras de nirK o pmoA, se descargan fácilmente mediante la interfaz de la página web. Sin embargo, para datasets mayores, la única posibilidad de acceso y descarga es a través de una herramienta llamada SRA-toolkit. El principal problema que encontré fue la documentación confusa y contradictoria. Debido a los cambios de versión a versión, se podían encontrar diferentes tipos de informaciones que resultaban contradictorias y dificultaban el proceso. El mayor problema que le atribuiría a esta herramienta es la falta de feedback que aporta al utilizarla. Para realizar los análisis tuvimos que descargar más de 150 GB de secuencias,

repartidas en 9 archivos. Este proceso tomó mucho tiempo, el cual se alargó debido a que el ordenador tenía que estar completamente activo y conectado a internet y ante cualquier problema, el proceso se detenía. Habría agradecido que, durante las largas descargas, la herramienta aportase un pequeño feedback del proceso y su estado, para haber conocido mejor la situación.

Los datos procesados están mal presentados, un poco una chapuza, hay estadísticos incoherentes, pvalores sin sentido, columnas repetidas, datos mal estructurados. Los métodos están explicados regular, es difícil asociar un método con unos datos, las figuras mezclan diferentes resultados y no los describen correctamente en los pies de figura.

En el desarrollo de métodos, no se informa de los parámetros empleados en QIIME2. Además, falta mucha información del protocolo empleado realmente. Esto dificulta bastante la replicabilidad. Sobre todo, es bastante perjudicial la disponibilidad de los datos que dan. No todos los datos crudos están presentados, y los que si son accesibles tienen nombres poco intuitivos. Puede ser que para ellos se entienda bien de donde salen y para que se han empleado, pero para cualquier persona que no conozca suficiente, como es el caso, y esté intentando replicar los datos, dichos nombres le resultan confusos y contradicen la información expresada en el paper o la información suplementaria.

Mi opinión final, es que este proceso ha sido complicado, principalmente por la elección de paper. Pese a que a primera vista parecía un paper sencillamente replicable, bien explicado y accesible, con toda la información disponible. Conforme hemos ido avanzando hemos visto que han surgido bastantes dificultades, pero por una perspectiva de "*sunken cost*" ha llegado un momento en el que no queríamos volver a empezar. Considero que, para una persona que domine el campo y conozca bien la metodología y tenga interiorizados los básicos, este paper resultaría mucho más sencillo de entender y replicar. Pero al entrar con conocimientos muy básicos de algunos temas, aprendidos en el máster, considero que este paper realiza un mal trabajo a la hora de presentar sus datos de una manera accesible y sus métodos de una manera replicable. Falta información explícita, los nombres son contradictorios, se dan muchas cosas por asumidas, lo que dificulta enormemente su estudio.

2 Article:

Metabolic coupling between soil aerobic methanotrophs and denitrifiers in rice paddy fields


3 Abstract

In rice paddy fields there is a lot of microbial denitrification, typically linked to oxidation of electron donors such as methane (CH_4) in *anoxic* and *hypoxic* conditions.

Results: Positive relation between CH₄ oxidation and denitrification activities and genes. CH₄ and methanotroph addition promote gene expression in denitrification. There is a high importance of intermediates between aerobic CH₄ oxidation and denitrification

The justification of this paper is to understand the denitrification process to efficiently use nitrogen fertilizer and reduce greenhouse gases emissions (N_2O and CH_4).

It has been seen the relation between *anoxic* and *hypoxic* methane oxidation and denitrification. The problem is the taxa capable of those processes were not found in surface layer of paddy fields (is partially oxic because of diffusion of oxygen from rice roots). **over 70% of the produced CH₄ in hypoxic conditions is consumed by aerobic methanotrophs before escaping to the atmosphere.** It's been seen that CH₄ oxidation significantly promotes N removal via denitrification. However, the taxa and pathways in rice paddy fields remain unknown.



CH₄ may promote denitrification by cooperation between aerobic metanotrophs and denitrifiers via O₂ consumption and intermediates exchange. Some metanotrophs were capable of partial denitrification. **Hypothesis: Microbial aerobic CH₄ oxidation may promote soil denitrification in rice paddies by a mutualism process.**

1. Field survey across china
2. Microcosm experiments (Coupling between CH₄ oxidation and denitrification genes: *narG*, *nirK*, *nirS*, *norB*, *nosZi* and *nosZII*; unther CH₄ and aerobic metanotrophs addition)
3. DNA-SIP with MAGs and ¹³C-metabolomics.

5 Methods

5.1 Field survey

5.2 $^{13}\text{CH}_4$ -DNA-stable isotope probing (SIP)

DNA-SIP is a technique used to identify active microorganisms that assimilate particular carbon nutrients into cellular biomass.

You first start by incubating an environmental sample with the stable isotope labelled compound, $^{13}\text{CH}_4$ in this case. Then you extract and purify the DNA, which lets you retrieve the labelled and unlabelled DNA for subsequent molecular characterization.

5.3 Microcosm experiments

Microcosms are artificial, simplified ecosystems that are used to simulate and predict the behaviour of natural ecosystems under controlled conditions. Open or closed microcosms provide an experimental area for ecologists to study natural ecological processes.

5.4 ^{13}C -metagenome-assembled genomes

5.5 ^{13}C -metabolomics

Directed metabolomics aimed to detect some intermediates derived from $^{13}\text{CH}_4$ metabolism including formaldehyde, formate, short-chain fatty acids, and intermediates involved in the serine cycle, gluconeogenesis, pyruvate metabolism and TCA cycle. (ESI-). The raw data were processed by ChemStation Software by using the default parameters and assisting manual inspection to ensure the qualitative and quantitative accuracies of each compound. The correction of natural isotope abundance and MID were performed with IsoCor.

5.6 Stat analysis

6 Results

Relation between microbial CH_4 oxidation and denitrification in field survey: Wide variation in denitrification and methane oxidation activities and the abundance of its genes across China. A significant and positive relationship between denitrification rate and CH_4 -oxidizing activity. Positive correlation between *pmoA* (methane monooxygenase) and *nirK* and *nirS*. The structural equation modeling (SEM) reconfirmed those results. Correlation network analyses indicated linkages between potential aerobic methane oxidation and denitrification taxa.

Experimental coupling between aerobic CH_4 oxidation and denitrification: To verify the influence of aerobic CH_4 oxidation on denitrification,

we determined changes in N_2O emissions, NO_3^- consumption and the expression of denitrification genes under CH_4 addition in selected soils. The addition of methanotrophs also led to an overall increase in N_2O emissions and NO_3^- -N consumption compared to the control.

Microbial guilds associated with the coupling between aerobic CH_4 oxidation and denitrification: DNA-SIP experiments to identify key taxa associated with the coupling.

Genes and metabolic pathways associated with the coupling between aerobic CH_4 oxidation and denitrification: these denitrifying MAGs also enriched genes responsible for the activation of carbonaceous organics such as methanol, formaldehyde, formate, short-chain fatty acids, as well as small molecular organic acids involved in pyruvate, TCA cycle. We subsequently elucidate the ^{13}C -metabolites derived from the oxidation of $^{13}\text{CH}_4$ to support denitrification, through an examination of both the pattern of ^{13}C labeling fraction and the concentration of each metabolite.

7 Replication

Given that one main point of my TFM project is metabolomics, i will try to replicate the results in **Figure 5B** from the source data given in the article. The metabolomic data resulting of the mass spectrometry has already been integrated and normalized, as it is said in the *Methods* section, using ChemStation Software and IsoCor. The resulting data must be analyzed, in order to calculate significance, and represented. We will compare our significance results with theirs and propose improvements in case they were possible. We will use RStudio to perform this calculations.

After developing all the code and analyzing the data there is quite an extrange result. Most of the obtainde results are exactly the same. However, we find some discrepancies between the results we obtain and the ones are given. It is quite extrange given that we can only find changes in some data, while the rest is exactly the same.

We tried studying the outliers, to ensure that we were not considering some data that were discarded by the authors. Nevertheless, almost any outliers were found, and the ones discovered did not help us aproximate the author's results.

Besides, we realized that the authors did not thought about the multiple testing effect on the significance of the results. In the 5B Figure analysis a total of 18 test were performed, which, because of the nature of this tests, would lead to at least 1 of them being a false positive. Given the characteristics of this analysis performing Bonferroni correction would be too restrictive of a test for our necessities. In this case, we proposed the use of False Discovery Rate correction

QIIME2 (Galaxy): https://usegalaxy.eu/u/enrique_julia/w/qiime2neikervf
 Python/Bash:

Listing 1: Python example

```
import numpy as np

def incmatrix( genl1 , genl2 ):
    m = len( genl1 )
    n = len( genl2 )
    M = None #to become the incidence matrix
    VT = np.zeros( (n*m,1) , int ) #dummy variable

    #compute the bitwise xor matrix
    Ml = bitxormatrix( genl1 )

Replication of statystical analysis
```